UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática

TFG del Grado en Ingeniería Informática

título del TFG

Presentado por Nombre del alumno
en Universidad de Burgos — 28 de noviembre de 2025
Tutor: nombre tutor

UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática

D. nombre tutor, profesor del departamento de nombre departamento, área de nombre área.

Expone:

Que el alumno D. Nombre del alumno, con DNI dni, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado título de TFG.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 28 de noviembre de 2025

Vº. Bº. del Tutor:	Vº. Bº. del co-tutor:
D. nombre tutor	D. nombre co-tutor

Resumen

En este primer apartado se hace una **breve** presentación del tema que se aborda en el proyecto.

Descriptores

Palabras separadas por comas que identifiquen el contenido del proyecto Ej: servidor web, buscador de vuelos, android ...

Abstract

A **brief** presentation of the topic addressed in the project.

Keywords

keywords separated by commas.

Índice general

Índice general iii

Índice de figuras iv

Índice de tablas v

1. Introducción 1

2. Objetivos del proyecto 3

3. Conceptos teóricos 5
- 3.1. Secciones . . . 5
- 3.2. Conceptos teóricos de la Segmentación Semántica . . . 5
- 3.3. Referencias . . . 11
- 3.4. Imágenes . . . 12
- 3.5. Listas de items . . . 12
- 3.6. Tablas . . . 13

4. Técnicas y herramientas 15

5. Aspectos relevantes del desarrollo del proyecto 17

6. Trabajos relacionados 19

7. Conclusiones y Líneas de trabajo futuras 21

Bibliografía 23

Índice de figuras

3.1. Autómata para una expresión vacía 12

Índice de tablas

3.1. Herramientas y tecnologías utilizadas en cada parte del proyecto 13

1. Introducción

Descripción del contenido del trabajo y del estructura de la memoria y del resto de materiales entregados.

2. Objetivos del proyecto

Este apartado explica de forma precisa y concisa cuales son los objetivos que se persiguen con la realización del proyecto. Se puede distinguir entre los objetivos marcados por los requisitos del software a construir y los objetivos de carácter técnico que plantea a la hora de llevar a la práctica el proyecto.

3. Conceptos teóricos

Algunos conceptos teóricos de LaTeX [1].

3.1. Secciones

Las secciones se incluyen con el comando section.

Subsecciones

Además de secciones tenemos subsecciones.

Subsubsecciones

Y subsecciones.

3.2. Conceptos teóricos de la Segmentación Semántica

Visión por computadora

La Visión por Computadora, en el contexto de la Inteligencia Artificial, es la disciplina que se enfoca en el diseño y optimización de arquitecturas computacionales para realizar la proyección no lineal de datos de entrada dados por píxeles hacia espacios de características de alta dimensionalidad [1] que encapsulan información semántica estratificada.

[1] Créditos a los proyectos de Álvaro López Cantero: Configurador de Presupuestos y Roberto Izquierdo Amo: PLQuiz

El objetivo operacional es la predicción densa a nivel de píxel o la clasificación discriminativa de etiquetas [1, 14], utilizando mapeos jerárquicos de características y garantizando la solvencia de optimización en estructuras ultra-profundas mediante mecanismos residuales [6].

Aprendizaje Profundo

El Aprendizaje Profundo es un paradigma de machine learning basado en el uso de redes neuronales convolucionales (CNN) o arquitecturas alternativas como los *Transformers*, que han surgido como el enfoque dominante para el reconocimiento visual [6, 7]. Funciona de una forma que, una clase de hipótesis de altísima capacidad, realizada por composiciones profundas de operadores paramétricos y no linealidades puntuales, aprende representaciones jerárquicas de los datos optimizando un funcional de riesgo empírico.

El éxito del Aprendizaje Profundo se atribuye a su capacidad para trabajar con arquitecturas muy grandes y profundas, con millones de parámetros, logrando avances significativos en el reconocimiento de imágenes [11, 5, 10, 6]. Este resuelve la necesidad de los sistemas de visión de extraer la representación de características más efectiva a partir de datos complejos [10], automatizando lo que antes requería el diseño manual de características.

Estructuras ultra-profundas

En el marco del Aprendizaje Profundo, la profundidad de las representaciones y de la red es de importancia crucial para muchas tareas de reconocimiento visual [6, 7]. Las arquitecturas modernas han superado significativamente las redes iniciales, con modelos que han rebasado la barrera de las 100 capas [7]. Estas estructuras ultra-profundas buscan enriquecer los "niveles"de las características mediante el aumento del número de capas apiladas [6, 7].

Sin embargo, el aumento de la profundidad introduce un desafío fundamental: el problema de la degradación. La degradación ocurre cuando, al aumentar las capas apiladas, la precisión del entrenamiento se deteriora. Teóricamente, un modelo más profundo no debería tener un error de entrenamiento mayor que su contraparte menos profunda. El hecho de que esto suceda indica que los algoritmos de optimización actuales tienen dificultades para encontrar soluciones que optimicen estas estructuras ultra-profundas [6]. Esto se debe a que, a medida que la información o el gradiente pasan por

muchas capas, pueden desvanecerse antes de alcanzar el final o el inicio de la red [7].

Predición Densa, denominada: Dense prediction

La predicción densa es una formulación de inferencia estructurada en la que el sistema estima, para cada ubicación del dominio espacial de la entrada, una variable de salida perteneciente a un espacio de etiquetas o a un espacio continuo. En visión por computador abarca tanto clasificación por elemento, como regresión por elemento, dando lugar a campos de salida con fuerte dependencia local y coherencia geométrica.

Desde el punto de vista inductivo, estas tareas se benefician de la *equivarianza traslacional* propia de arquitecturas totalmente convolucionales, del acoplamiento multi-escala para capturar contexto y del control explícito del output stride para balancear resolución y campo receptivo. La naturaleza densa impone consideraciones de regularidad de frontera, conservación de detalles de alta frecuencia, manejo del desbalanceo de clases y robustez frente a los problemas introducidos por downsampling.

Operativamente, la predicción densa se implementa con encoders–decoders convolucionales que combinan downsampling para agregar contexto y upsampling para reconstruir resolución, asistidos por skip connections por concatenación para preservar información de detalle.

Segmentación Semántica

La segmentación semántica es una tarea de predicción densa en Visión por Computadora cuyo objetivo es la clasificación a nivel de píxel [3, 14], mediante la asignación de una etiqueta de clase semántica a cada píxel de una imagen de entrada. A diferencia de tareas como la clasificación, la segmentación semántica proporciona una comprensión completa del escenario, prediciendo así la categoría, ubicación y forma de cada elemento.

Este proceso típicamente se implementa a través de una arquitectura de red neuronal profunda de codificador-decodificador, llamada encoder-decoder de manera tradicional [14, 10, 3].

1. **Codificación mediante encoder:** El codificador, a menudo basado en una **Red Neuronal Convolucional (CNN)** [1] o un **Vision Transformer (ViT)** [3], toma la imagen de entrada y transforma los datos de esta en una representación de características de alto

nivel mediante una reducción de la resolución espacial a través de diversas operaciones como podrían ser el **max-pooling** o el uso de **capas convolucionales**, obteniendo así como resultado unas capas de características de baja resolución pero semánticamente ricas.

2. **Decodificación por decoder:** El decodificador opera con las características comprimidas del codificador para reconstruir la predicción final. Esto lo hará mediante la utilización de operaciones de **sobremuestreo**, a menudo implementadas mediante **upsampling** [2, 9] o mediante el uso de índices de **max-pooling** [10, 14], agrandando la entrada para extraer características de alta resolución [10, 14, 2].

3. **Salida y Optimización:** La salida final es un mapa de segmentación que se alimenta a una capa **Softmax** para asignar probabilidades de clasificación a cada píxel de forma independiente [14, 3, 10], generando una **predicción densa** [10, 3].

Mecanismos Residuales

Los mecanismos residuales son esquemas de conexión aditiva que introducen **skip connections** a través de los bloques de una red profunda, de modo que la transformación aprendida se formula como una corrección respecto de la señal que fluye sin distorsión por el atajo [6]. Esta arquitectura estabiliza la propagación hacia delante y hacia atrás, mejora el acondicionamiento efectivo del problema de optimización y habilita redes sustancialmente más profundas; cuando existe desajuste de dimensionalidad, la ruta de identidad se implementa mediante proyecciones, mientras que otras variantes con saltos de identidad estrictos refuerzan el transporte directo de información y gradientes. En conjunto, los mecanismos residuales facilitan el aprendizaje de funciones de alta complejidad al mantener rutas de baja impedancia para el flujo de señales [12].

Skip Connections

Conexiones encargadas de mitigar la pérdida de información espacial que ocurre durante el **downsampling** en el codificador. Transfieren características de alta resolución desde las capas tempranas del codificador a las capas correspondientes del decodificador, fusionando las características codificadas con los detalles espaciales finos, siendo estos los límites y contornos, del inicio de la red. Para lograr esto, se emplea una **capa de concatenación** que fusiona la salida de las **capas convolucionales** del **encoder** con las **capas de deconvolución** del **decoder**.

Upsampling

El upsampling, también denominado **deconvolución**, es la función principal del **decodificador**, definida como la operación de mapeo que transforma representaciones de características comprimidas de baja resolución en mapas de características de alta resolución espacial para la clasificación a nivel de píxel. Esto puede implementarse mediante **interpolación**, **convolución transpuesta** o **decodificadores MLP**. La implementación también puede optar por utilizar métodos sin aprendizaje, aunque esto puede resultar en un rendimiento inferior en comparación con los métodos que sí aprenden del entorno. Para preservar los contornos finos y garantizar la localización precisa, el decodificador se basa en la fusión de características de niveles previos del codificador mediante **skip connections**.

downsampling

El downsampling es una técnica fundamental utilizada en las **redes neuronales convolucionales** y en el **encoder** de las arquitecturas de **codificador-decodificador** para transformar la información de entrada en una representación de características reducida de alto nivel. El propósito central de esta operación es doble: por un lado, aliviar la carga computacional y prevenir el *overfitting*; por otro lado, lograr una mayor **invarianza traslacional** sobre pequeños desplazamientos espaciales en la imagen de entrada, lo cual robustece la clasificación. Esto se realiza a costa de una pérdida progresiva de la resolución espacial en los mapas de características, lo cual reduce el detalle de los límites, un factor que debe compensarse en la fase de decodificación.

El mecanismo principal para lograr el submuestreo es la operación de **max-pooling**, que es el núcleo del downsampling y se utiliza para disminuir el tamaño del mapa de características. Lo que hace para llevarlo a cabo es dividir dicho mapa de entrada en pequeñas regiones o ventanas. Tras ello, extrae el valor máximo dentro de una de las ventanas, utilizándolo como el único valor representativo para esa área en el nuevo mapa de características reducido. Finalmente, la ventana se desliza a lo largo de la imagen con un *stride* predefinido, repitiendo la operación.

Aunque las sucesivas capas de max-pooling y submuestreo pueden lograr una mayor invarianza para una clasificación robusta, la contraparte es una pérdida progresiva de la resolución espacial en los mapas de características. Esta pérdida resulta en una representación cada vez más inexacta en cuanto al detalle de los límites de los objetos, lo cual es perjudicial para tareas de

predicción densa, como la segmentación, donde la delineación precisa es vital. Sin embargo, el downsampling tiene un beneficio inherente: logra que cada píxel en el mapa de características posterior abarque un contexto de imagen de entrada más grande.

Red Neuronal Convolucional (CNN)

Una Red Neuronal Convolucional es una arquitectura de **aprendizaje profundo** que se ha convertido en el enfoque dominante para el reconocimiento visual de objetos. Implementa sesgos inductivos inherentes, como la **covarianza traslacional**, para la extracción eficiente de características jerárquicas, integrando naturalmente características de nivel bajo, medio y alto. En un contexto de **predicción densa**, como la **segmentación semántica**, la CNN se extiende típicamente en un marco de **codificador-decodificador** para realizar una clasificación a nivel de píxel. El funcionamiento en la segmentación se basa en este marco bifásico de codificación y decodificación:

1. **Capas Convolucionales, conocidas como: Convolutional Layers** Las capas convolucionales son el núcleo de la CNN y componen la ruta principal del codificador. En estas, se realiza la operación de **convolución**, que utiliza un conjunto de *kernels* con pesos entrenables para convertir los datos de entrada en mapas de características. El kernel se desliza sobre la entrada con un *stride* para producir la salida espacial. Mediante este proceso de **downsampling** codifica la información de entrada en una representación de características de alto nivel downsampleada.

2. **Capas Deconvolucionales, también conocidas como: Deconvolutional Layers** Las capas deconvolucionales son el mecanismo de **upsampling** más común utilizado en la ruta del decodificador. Mediante el uso de esta técnica, consiguen mapear los mapas de características comprimidos de baja resolución a mapas de características que se aproximan a la resolución de entrada original. El desafío al que se deben enfrentar estas capas es que pueda suceder que la red tienda a ignorar los detalles, lo que conlleve una salida insatisfactoria.

3. **Capa de Concatenación, comunmente: Concatenation Layer** La capa de concatenación es un componente de fusión de características utilizado en el **decodificador** para mejorar la precisión espacial. Para lograr este objetivo, fusiona las características de salida de las **capas convolucionales** del **codificador** con las características de

las **capas deconvolucionales** del **decodificador**. Dicha fusión se logra a través del uso de **skip connections**, que copian los mapas de características de alta resolución y bajo nivel semántico desde el **codificador** hacia el **decodificador**. La concatenación expande estos mapas y, al combinar las características espaciales detalladas con las características semánticas restauradas, asegura una delineación precisa de los límites en la predicción final.

Vision Transformer (ViT)

La arquitectura del Vision Transformer (ViT) se erige como el paradigma dominante después de las **CNN** en tareas de reconocimiento visual. Opera al inicio con una fase de tokenización no superpuesta, donde la imagen de entrada es segmentada en parches, aplanados, y proyectados linealmente mediante una transformación a un espacio embedido. A estos embeddings se les adjuntan codificaciones posicionales para conservar la información espacial. Esta secuencia de tokens enriquecida se introduce en un **encoder** de Transformer que consiste en múltiples bloques idénticos, equipados con el mecanismo de Multi-Head Self-Attention. El **self-attention** permite que cada token capture relaciones de largo alcance y el contexto global con todos los demás tokens, facilitando una interpretación más inclusiva de patrones intrincados en los datos. En el contexto de la **segmentación densa**, el encoder ViT finaliza su proceso entregando características codificadas de bajo nivel espacial pero semánticamente ricas. La arquitectura completa luego emplea un **decodificador** para reconstruir el mapa de segmentación. Este decodificador típicamente incluye capas de **upsampling** para aumentar la resolución espacial de las características comprimidas y utiliza **skip connections** para transferir características de alta resolución desde el encoder y así reconstruir el mapa de segmentación con alta fidelidad. La salida final se genera a través de una **capa convolucional** seguida de una activación **Softmax**, proporcionando un mapa de probabilidades detallado para la clasificación a nivel de píxel.

3.3. Referencias

Las referencias se incluyen en el texto usando cite [13]. Para citar webs, artículos o libros [8], si se desean citar más de uno en el mismo lugar [4, 8].

3.4. Imágenes

Se pueden incluir imágenes con los comandos standard de LaTeX, pero esta plantilla dispone de comandos propios como por ejemplo el siguiente:

Figura 3.1: Autómata para una expresión vacía

3.5. Listas de items

Existen tres posibilidades:

- primer item.
- segundo item.

1. primer item.
2. segundo item.

Primer item más información sobre el primer item.

Segundo item más información sobre el segundo item.

-

Herramientas	App AngularJS	API REST	BD	Memoria
HTML5	X			
CSS3	X			
BOOTSTRAP	X			
JavaScript	X			
AngularJS	X			
Bower	X			
PHP		X		
Karma + Jasmine	X			
Slim framework		X		
Idiorm		X		
Composer		X		
JSON	X	X		
PhpStorm	X	X		
MySQL			X	
PhpMyAdmin			X	
Git + BitBucket	X	X	X	X
MikTEX				X
TEXMaker				X
Astah				X
Balsamiq Mockups	X			
VersionOne	X	X	X	X

Tabla 3.1: Herramientas y tecnologías utilizadas en cada parte del proyecto

3.6. Tablas

Igualmente se pueden usar los comandos específicos de LATEXo bien usar alguno de los comandos de la plantilla.

4. Técnicas y herramientas

Esta parte de la memoria tiene como objetivo presentar las técnicas metodológicas y las herramientas de desarrollo que se han utilizado para llevar a cabo el proyecto. Si se han estudiado diferentes alternativas de metodologías, herramientas, bibliotecas se puede hacer un resumen de los aspectos más destacados de cada alternativa, incluyendo comparativas entre las distintas opciones y una justificación de las elecciones realizadas. No se pretende que este apartado se convierta en un capítulo de un libro dedicado a cada una de las alternativas, sino comentar los aspectos más destacados de cada opción, con un repaso somero a los fundamentos esenciales y referencias bibliográficas para que el lector pueda ampliar su conocimiento sobre el tema.

5. Aspectos relevantes del desarrollo del proyecto

Este apartado pretende recoger los aspectos más interesantes del desarrollo del proyecto, comentados por los autores del mismo. Debe incluir desde la exposición del ciclo de vida utilizado, hasta los detalles de mayor relevancia de las fases de análisis, diseño e implementación. Se busca que no sea una mera operación de copiar y pegar diagramas y extractos del código fuente, sino que realmente se justifiquen los caminos de solución que se han tomado, especialmente aquellos que no sean triviales. Puede ser el lugar más adecuado para documentar los aspectos más interesantes del diseño y de la implementación, con un mayor hincapié en aspectos tales como el tipo de arquitectura elegido, los índices de las tablas de la base de datos, normalización y desnormalización, distribución en ficheros3, reglas de negocio dentro de las bases de datos (EDVHV GH GDWRV DFWLYDV), aspectos de desarrollo relacionados con el WWW... Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

6. Trabajos relacionados

Este apartado sería parecido a un estado del arte de una tesis o tesina. En un trabajo final grado no parece obligada su presencia, aunque se puede dejar a juicio del tutor el incluir un pequeño resumen comentado de los trabajos y proyectos ya realizados en el campo del proyecto en curso.

7. Conclusiones y Líneas de trabajo futuras

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas. Además, resulta muy útil realizar un informe crítico indicando cómo se puede mejorar el proyecto, o cómo se puede continuar trabajando en la línea del proyecto realizado.

Bibliografía

[1] Vision encoder: Architectures, training, efficiency, and applications. Technical report, 2025. Unpublished manuscript.

[2] Vijay Badrinarayanan, Alex Kendall, and Roberto Cipolla. Segnet: A deep convolutional encoder-decoder architecture for image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017. arXiv:1511.00561.

[3] Saroj Bala, Kumud Arora, Jeevitha R, Rini Chowdhury, Prashant Kumar, and Shobana Nageswari C. A novel encoder decoder architecture with vision transformer for medical image segmentation. *Journal of Electronics, Electromedical Engineering, and Medical Informatics*, 7(1):176–186, 2025.

[4] Zachary J Bortolot and Randolph H Wynne. Estimating forest biomass using small footprint lidar data: An individual tree-based approach that incorporates training data. *ISPRS Journal of Photogrammetry and Remote Sensing*, 59(6):342–360, 2005.

[5] José Francisco Díez-Pastora, Francisco Javier González-Moya, Pedro Latorre-Carmona, Francisco Javier Pérez-Barbería, Ludmila Kuncheva, Antonio Canepa-Oneto, Álvar Arnaiz-González, and César García-Osorio. Remote sensing colour image semantic segmentation of large herbivorous mammals trails. *Remote Sensing (submitted manuscript)*, 2025. Manuscript compiled May 19, 2025. Author's Original Manuscript (AOM) available in arXiv.

[6] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE*

Conference on Computer Vision and Pattern Recognition (CVPR), pages 770–778. IEEE, 2016.

[7] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4700–4708, 2017.

[8] John R. Koza. *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press, 1992.

[9] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 936–944. IEEE, 2017.

[10] Asif Ahmed Neloy and Maxime Turgeon. A comprehensive study of auto-encoders for anomaly detection: Efficiency and trade-offs. *Machine Learning with Applications*, 17:100572, 2024.

[11] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241. Springer, 2015.

[12] Rupesh Kumar Srivastava, Klaus Greff, and Jürgen Schmidhuber. Highway networks. In *Proceedings of the Deep Learning Workshop at the 32nd International Conference on Machine Learning (ICML)*. arXiv preprint arXiv:1505.00387, 2015.

[13] Wikipedia. Latex — wikipedia, la enciclopedia libre. https://es.wikipedia.org/w/index.php?title=LaTeX&oldid=84209252, 2015. [Internet; descargado 30-septiembre-2015].

[14] et al. Zhang. Paper published in automation in construction. *Automation in Construction*, 2022. Elsevier article extracted from PDF 1-s2.0-S0926580522000607.